

## 국제 AI 안전 보고서, 범용 AI 발전에 따른 새로운 위험 요소 우려



국제 AI 안전 보고서, 새로운 추론 모델이 수학, 코딩 등 복잡한 문제 해결 능력을 비약적으로 발전시켰으나, 이는 AI 거버넌스에 새로운 과제를 제기한다고 지적



특히 AI의 성능 향상은 생물학적 위험 및 사이버 범죄를 강화할 이중 용도 CBRN(화학·생물·방사능·핵) 관련 위협으로 이어져, 개발사들은 선제적인 안전 조치 준비 중

### ▶ AI 안전 정상회의의 약속, 국제 AI 안전 보고서

2023년 블레츨리 AI 안전 정상회의는 첨단 AI 시스템의 안전을 국제적 최우선 과제로 설정하고, 합의에 따라 2025년 1월 첫 국제 AI 안전 보고서가 발간되었다. 이 보고서는 각국의 AI 안전 정책 수립을 위한 핵심 참고 자료로 활용되며 국제적 공조의 기반이 되고 있는데, 최근 10월에 공개된 첫번째 업데이트 버전은 범용 AI(General-Purpose AI)의 수행 능력과 내재된 주요 위험 요소를 집중적으로 분석했다.

### ▶ '생각하는 AI'의 등장: 사후 훈련 기법이 혁신을 이끌다

2025년 초 이후 범용 AI 시스템의 성능은 크게 개선되었는데, 이는 단순히 모델 크기를 키우는 게 아닌, **사후 훈련 기법** (Post-training techniques) 혁신을 통해 문제를 단계적으로 분석하고 해결 절차를 스스로 구성하도록 설계된 **추론 모델**은, 국제 수학 올림피아드 문제를 금메달 수준으로 해결했으며, 실제 소프트웨어 엔지니어링 작업 데이터베이스인 'SWE-bench Verified' 문제의 60% 이상을 완료하는 등, 복잡한 영역에서 주요 발전을 달성했다.

### ▶ 성능 향상의 어두운 그림자, 이중 용도 CBRN 위험에 대한 선제 대응 노력

범용 AI의 향상된 문제 해결 능력과 확장된 자율 작동 능력은 **이중 용도(Dual-use) 위험**을 증폭시킨다. 이중 용도 위험은 본래 인간의 합법적 목적을 위해 개발된 기술이 의도와 달리 군사적 목적 또는 해로운 방식으로 사용될 수 있는 가능성을 뜻하는데, 특히, 선도적인 모델들이 생물학 무기 개발 관련 작업을 지원할 수 있다는 평가가 나오면서 이중 용도 CBRN 위험에 대한 우려가 커졌다. 한 연구에 따르면, 현재의 언어 모델은 제한된 조건에서 바이러스학 전문가보다 바이러스 연구실 프로토콜의 문제 해결을 더 잘 수행하는 것으로 나타났다. 또한, 영국 국립 사이버 보안 센터(NCSC)는 2027년까지 범용 AI가 사이버 공격의 효율성을 높여 사이버 범죄를 더욱 쉽고 효과적으로 만들 것으로 예측했다. 이에 따라 Anthropic은 Claude 4 Opus에 'AI 안전 레벨 3(ASL-3)' 보호 조치를 적용하고, OpenAI는 GPT-5에 높은 수준의 안전 장치를 적용하는 등, 개발사들은 위험의 결정적 증거가 부족함에도 불구하고 선제적이고 예방적인 조치들을 시행하고 있다.

**10월의 용어** 사후 훈련 기법, 추론 모델, 이중 용도 위험

출처 : 1) The UK Government(2025. 10.), International AI Safety Report 2025: First Key Update: Capabilities and Risk